

Aritmética de ponto flutuante

Lilian Berti

Métodos Numéricos

Aritmética de ponto flutuante

Exemplo: Calcule a área de uma circunferência em que o raio é 100m.

$$A = \pi r^2 = 3,14 \cdot 10000 = 31.400m^2$$

$$(\text{ou } A = 3,1416 \cdot 10000 = 31.416m^2$$

$$\text{ou } A = 31.415,9265m^2)$$

Como justificar as diferenças entre os resultados? É possível obter o valor exato desta área?

Aritmética de ponto flutuante

Um número real tem a seguinte forma geral de representação:

$$\pm 0, d_1 d_2 \cdots d_t \times \beta^E$$

em que: d_i 's são os dígitos da parte fracionária, $0 \leq d_i \leq \beta - 1$, $i = 1, \dots, t$, β é o valor da base, t é os dígitos da mantissa e E é o expoente inteiro ($l \leq E \leq u$). Se $d_1 \neq 0$ diz se que o número está normalizado.

Notação: $F(\beta, t, l, u)$

Exemplos

1) Representação de $\pi = 3,141592653 \dots$

a) $F(10, 3, -2, 2)$

$$\pi = 0,314 \times 10^1$$

b) $F(10, 5, -2, 2)$

$$\pi = 0,31416 \times 10^1$$

2) Considere o sistema $F(10, 3, -4, 4)$

x	Representação
-279	$-0,279 \times 10^3$
1,25	$0,125 \times 10^1$
0,0123	$0,123 \times 10^{-1}$
-0,0000052	$-0,52 \times 10^{-6}$ (erro underflow)
123456	$0,123 \times 10^6$ (erro overflow)

3) Qual o maior e o menor valor em módulo representado no sistema $F(10, 3, -4, 4)$?

menor: $m = 0,100 \times 10^{-4} = 10^{-5} = 0,00001$

Maior: $M = 0,999 \times 10^4 = 9990$

Considere $x = 0, d_1 d_2 d_3 \dots d_t d_{t+1} \dots$

Aproximação com t dígitos por arredondamento:

Se $d_{t+1} < 5 \Rightarrow x = 0, d_1 d_2 d_3 \dots d_t$

Se $d_{t+1} \geq 5 \Rightarrow x = 0, d_1 d_2 d_3 \dots (d_t + 1)$

Exemplo: Seja $F(10, 3, -4, 4)$

Arredondamento

$\sqrt{2} = 1,41421356 \dots$ $0,141 \times 10$

$e = 2,71828182 \dots$ $0,272 \times 10$

$100,5$ $0,101 \times 10^3$

Operações em aritmética de ponto flutuante com três dígitos significativos e arredondamento

a) $(11,4 + 3,18) + 5,05 = 14,6 + 5,05 = 19,7$

b) $11,4 + (3,18 + 5,05) = 11,4 + 8,23 = 19,6$

c) $\frac{3,18 \times 11,4}{5,05} = \frac{36,3}{5,05} = 7,19$

d) $\frac{3,18}{5,05} \times 11,4 = 0,63 \times 11,4 = 7,18$

e) $3,18 \times (5,05 + 11,4) = 3,18 \times 16,5 = 52,5$

f) $3,18 \times 5,05 + 3,18 \times 11,4 = 16,1 + 36,3 = 52,4$

OBS: As operações aritméticas não são associativas e distributivas

Erros:

Sejam x um número exato e $\bar{x}$ uma aproximação para x .

Erro absoluto:

$$E_A(\bar{x}) = |x - \bar{x}|$$

Erro relativo:

$$E_R(\bar{x}) = \frac{|x - \bar{x}|}{|x|}, \quad x \neq 0$$

Exemplos:

a) $x = 1$ e $\bar{x} = 1,373$

$$E_A(\bar{x}) = |1 - 1,373| = 0,373$$

$$E_R(\bar{x}) = \frac{|1 - 1,373|}{1} = 0,373$$

b) $x = 3876$ e $\bar{x} = 3876,373$

$$E_A(\bar{x}) = |3876 - 3876,373| = 0,373$$

$$E_R(\bar{x}) = \frac{|3876 - 3876,373|}{|3876|} = 0,000096$$

Exemplo: Considere o sistema de ponto flutuante com cinco dígitos significativos. Seja $x = 49213 + 31,728 - 49244$. Temos:

Valor Exato:

$$x = 0,728$$

Valor aproximado:

$$\bar{x} = 49213 + 31,728 - 49244 = 49245 - 49244 = 1$$

$$E_R(\bar{x}) = \frac{|0,728 - 1|}{|0,728|} = 0,37363$$

Note que, o erro relativo na adição inicial é:

$$E_R = \frac{|49244,728 - 49245|}{|49244,728|} = 5,5243 \times 10^{-6}$$

Os dígitos perdidos na adição passa a ser importante na subtração.